
Predicción del éxito académico en educación superior

Sofía Sánchez Guillán
Universidad Pontificia de Comillas
Grado en Ingeniería Matemática e Inteligencia Artificial
Marzo 2026

Abstract

En este trabajo analizamos el éxito académico en educación superior mediante técnicas de aprendizaje automático. Se abordan tres tareas: clasificación, regresión y análisis no supervisado.

Se evalúan distintos modelos, obteniendo un rendimiento global similar y destacando dificultades en la predicción de clases minoritarias. Asimismo, los resultados muestran la presencia de relaciones no lineales y permiten identificar distintos perfiles de estudiantes.

En conjunto, el rendimiento en el primer semestre se confirma como el principal factor asociado a la trayectoria académica.

1 Introducción

En este trabajo analizamos el éxito académico en educación superior mediante técnicas de aprendizaje automático, utilizando un conjunto de datos con información demográfica, socioeconómica y académica.

El objetivo es no solo predecir la situación final del estudiante, sino también comprender los factores que influyen en su trayectoria. Para ello, abordamos tres tareas: clasificación, regresión y análisis no supervisado.

A lo largo del estudio evaluamos distintos modelos y analizamos su rendimiento, prestando especial atención a aspectos como el desbalanceo de clases y la complejidad de las relaciones presentes en los datos.

2 Exploración inicial y análisis descriptivo del conjunto de datos (EDA)

En primer lugar, realizamos un análisis exploratorio del conjunto de datos con el objetivo de comprender su estructura y características principales. Para ello, analizamos el número de observaciones y variables, así como el tipo de cada una de ellas, identificando un total de 19 variables numéricas y 18 variables categóricas.

A continuación, examinamos la variable objetivo, que representa la situación final del estudiante, con tres posibles clases: *abandono*, *matriculado* y *graduado*. El análisis de su distribución pone de manifiesto un claro desbalanceo entre clases, siendo *graduado* la más frecuente y *matriculado* la menos representada. Este aspecto resulta especialmente relevante, ya que influye directamente en el rendimiento de los modelos y en la elección de métricas de evaluación adecuadas.

Además, observamos que las variables numéricas presentan distintas magnitudes, lo que implica que se encuentran en diferentes escalas. Por este motivo, consideramos necesario aplicar técnicas de normalización en la fase de preprocesado para garantizar un comportamiento adecuado de los modelos sensibles a la escala, como la regresión logística o SVM.

A partir de este análisis inicial, definimos una estrategia de preprocesado diferenciada para variables numéricas y categóricas, que será aplicada posteriormente mediante herramientas específicas como *StandardScaler* y *OneHotEncoder*.

3 Preprocesado realizado y decisiones metodológicas adoptadas

Tras el análisis exploratorio, llevamos a cabo una fase de preprocesado con el objetivo de preparar los datos para su uso en modelos de aprendizaje supervisado.

En relación con los valores atípicos, realizamos un análisis tanto para variables numéricas como categóricas. En el caso de las variables numéricas, se empleó el criterio del rango intercuartílico (IQR), identificando el porcentaje de valores extremos en cada variable. Observamos que algunas, especialmente las relacionadas con el rendimiento académico, presentan una proporción significativa de outliers como vemos en la figura 4. Sin embargo, estos valores no corresponden a errores de medición, sino a comportamientos reales del alumnado, por lo que decidimos no eliminarlos para evitar introducir sesgos en el modelo.

En cuanto a las variables categóricas, analizamos la distribución de frecuencias y detectamos la presencia de categorías poco representadas. Estas pueden considerarse análogas a valores atípicos en variables categóricas. No obstante, se optó por mantenerlas, ya que pueden aportar información relevante sobre perfiles minoritarios de estudiantes. El uso de técnicas como One-Hot Encoding permite gestionar adecuadamente estas categorías sin afectar negativamente al rendimiento de los modelos.

Asimismo, separamos las variables en función de su tipo, distinguiendo entre variables numéricas (*int64* y *float64*) y variables categóricas (*object*). Esta diferenciación permite aplicar un tratamiento específico a cada tipo de variable.

Para las variables numéricas, aplicamos un proceso de escalado mediante *StandardScaler*, con el fin de normalizar sus valores y evitar que las diferencias de magnitud influyan negativamente en el rendimiento de modelos sensibles a la escala, como la regresión logística o las máquinas de vectores soporte.

Por otro lado, las variables categóricas se transforman mediante *OneHotEncoder*, convirtiéndolas en variables binarias. Además, se utiliza el parámetro *handle_unknown='ignore'* para evitar errores en caso de que aparezcan categorías no vistas durante el entrenamiento en los conjuntos de validación o test.

Ambas transformaciones se integran mediante un *ColumnTransformer*, lo que permite aplicar de forma conjunta y coherente el preprocesado a cada tipo de variable dentro de un mismo flujo de trabajo.

Es importante destacar que el preprocesado se ajusta únicamente con el conjunto de entrenamiento, aplicándose posteriormente a los conjuntos de validación y test mediante el método *transform*. De este modo, evitamos introducir información del futuro en el modelo y garantizamos una evaluación correcta.

Como resultado, obtenemos un conjunto de datos transformado y adecuado para su uso en los distintos modelos de aprendizaje automático.

4 Implementación y evaluación en la tarea de clasificación

En esta fase abordamos la construcción y evaluación de distintos modelos de clasificación supervisada con el objetivo de predecir la situación final del estudiante entre las clases *abandono*, *matriculado* y *graduado*.

Para ello, dividimos el conjunto de datos en tres subconjuntos: entrenamiento, validación y test. El conjunto de entrenamiento se utilizó para ajustar los modelos, el de validación para comparar su rendimiento y seleccionar el más adecuado, y el de test se reservó exclusivamente para la evaluación final, garantizando así una estimación realista del comportamiento del modelo en datos no vistos. Además, empleamos una partición estratificada para preservar la distribución de la variable objetivo en cada subconjunto.




Figure 1: Outliers en variables numéricas

A continuación, implementamos diversos modelos de clasificación con el objetivo de analizar su comportamiento específico en la predicción de la situación final del estudiante. Es importante destacar que, en todos los casos, eliminamos previamente las variables del segundo semestre, con el fin de evitar el uso de información futura y construir un modelo más realista desde el punto de vista predictivo.

En primer lugar, utilizamos una regresión logística como modelo base. Este modelo permitió establecer una referencia sólida, mostrando un comportamiento equilibrado entre clases incluso tras eliminar las variables del segundo semestre. En particular, destacó por su capacidad para identificar la clase *matriculado*, la más difícil de predecir, lo que indica que es capaz de generalizar adecuadamente en un escenario donde la información disponible es limitada.

Posteriormente, implementamos un modelo de Random Forest, que permitió capturar relaciones no lineales entre las variables. Sin embargo, en este problema concreto, el modelo mostró una clara tendencia a favorecer las clases mayoritarias, especialmente *graduado*, lo que se tradujo en un rendimiento inferior en la clase *matriculado*, con valores de recall significativamente bajos. Esto sugiere que, aunque el modelo es potente, no logra discriminar adecuadamente esta categoría en ausencia de información más cercana al resultado final.

A continuación, utilizamos Gradient Boosting, que introdujo una mejora en el rendimiento global del modelo. Su enfoque secuencial permitió capturar mejor ciertos patrones complejos en los datos, logrando el mayor F1-score ponderado entre los modelos evaluados. En este contexto, el modelo mostró un mejor ajuste global, especialmente en la clase *graduado*, aunque, al igual que otros modelos, continuó presentando dificultades para identificar correctamente la clase *matriculado*.

Finalmente, implementamos un modelo de Máquinas de Vectores Soporte (SVM), que permitió obtener un comportamiento más equilibrado entre clases. En particular, este modelo destacó por su capacidad para mejorar la detección de la clase *matriculado*, alcanzando los mejores valores de recall en esta categoría. No obstante, esta mejora se produjo a costa de un ligero descenso en el rendimiento global respecto a Gradient Boosting.

En conjunto, la comparación de estos modelos pone de manifiesto que, en este problema, la principal dificultad radica en la identificación de la clase "matriculado", y que las diferencias entre modelos vienen determinadas por su capacidad para gestionar este desequilibrio, más que por mejoras sustanciales en el rendimiento global.

Para la evaluación de los modelos, utilizamos como métrica principal el F1-score ponderado, ya que el dataset presenta desbalanceo entre clases y esta métrica permite tener en cuenta tanto la precisión como el recall de cada categoría. Adicionalmente, analizamos el rendimiento por clase mediante el classification report y la matriz de confusión, lo que nos permitió identificar el comportamiento específico de los modelos en cada una de las clases. Además, aplicamos validación cruzada para evaluar la estabilidad de los modelos como podemos ver en la figura 1.

Los resultados obtenidos muestran que todos los modelos presentan un rendimiento global similar, con valores de F1-score ponderado en torno a 0.72–0.75. En particular, Gradient Boosting alcanza

el mejor rendimiento global, seguido de SVM y regresión logística, mientras que Random Forest presenta un comportamiento ligeramente inferior.

No obstante, el análisis detallado por clases revela diferencias relevantes entre modelos. La clase "graduado" es la mejor predicha por todos los modelos, mientras que "abandono" presenta un rendimiento intermedio. Por el contrario, la clase "matriculado" resulta ser la más difícil de identificar, especialmente en modelos como Random Forest, que muestran un recall muy bajo en esta categoría.

En este contexto, la regresión logística y SVM destacan por ofrecer un comportamiento más equilibrado entre clases, siendo SVM el modelo que mejor identifica la clase "matriculado". Por su parte, Gradient Boosting mejora el rendimiento global, aunque no resuelve completamente las dificultades asociadas a esta clase minoritaria.

Como complemento, analizamos la capacidad de discriminación de los modelos mediante la curva ROC en un contexto multiclase (one-vs-rest), observando valores de AUC elevados y muy similares entre modelos (en torno a 0.85–0.86), como vemos en la figura 2. Este resultado confirma que todos los modelos capturan adecuadamente la estructura del problema, y que las diferencias de rendimiento son limitadas.

En conjunto, los resultados indican que el límite del rendimiento viene determinado principalmente por la información disponible en el dataset, más que por la elección del modelo. Por tanto, finalmente elegimos Gradient Boosting por su mejor rendimiento global, aunque la clase "matriculado" sigue siendo la más difícil de predecir.




Figure 2: Resultados de clasificación

5 Implementación y evaluación de la tarea de regresión

En esta tarea abordamos un problema de regresión supervisada cuyo objetivo es predecir la variable `nota_media_2sem`.

Para ello, eliminamos todas las variables correspondientes al segundo semestre, excepto la variable objetivo, para evitar la presencia de fuga de información (data leakage).

Posteriormente, realizamos una partición de los datos en tres subconjuntos: entrenamiento, validación y test. El conjunto de test se ha mantenido completamente aislado durante todo el proceso, utilizándose exclusivamente para la evaluación final del modelo.

Para evaluar el rendimiento de los modelos utilizamos las métricas MAE, RMSE y R^2 . El MAE proporciona una medida interpretable del error medio, el RMSE penaliza en mayor medida los errores grandes, y el R^2 permite cuantificar la proporción de la variabilidad explicada por el modelo. Estas métricas permiten obtener una visión completa de los modelos en un problema de regresión.

Evaluamos distintos modelos con el objetivo de analizar el impacto de la complejidad del modelo en el rendimiento: regresión lineal como modelo base, modelos lineales regularizados (Ridge y Lasso) y modelos no lineales basados en árboles (Random Forest y Gradient Boosting).

En primer lugar, utilizamos regresión lineal como referencia, ya que permite establecer una línea base sencilla e interpretable, basada en la relación lineal entre las variables predictoras y la variable objetivo. Este modelo proporciona un punto de comparación útil para evaluar el beneficio de introducir mayor complejidad en el modelado.

A continuación, incorporamos modelos lineales regularizados como Ridge y Lasso, que introducen penalizaciones sobre los coeficientes con el objetivo de reducir el sobreajuste y mejorar la capacidad de generalización. Mientras que Ridge tiende a reducir de forma suave los coeficientes, Lasso puede llegar a anular algunos de ellos, actuando además como mecanismo de selección de variables. Estos modelos resultan especialmente útiles en presencia de multicolinealidad o cuando se busca simplificar la interpretación del modelo.

Por último, evaluamos modelos no lineales basados en árboles, como Random Forest y Gradient Boosting, que permiten capturar relaciones más complejas entre variables sin necesidad de asumir una forma funcional específica. Random Forest combina múltiples árboles entrenados de forma independiente, lo que mejora la estabilidad del modelo, mientras que Gradient Boosting construye los árboles de manera secuencial, corrigiendo los errores de los anteriores y logrando un ajuste más preciso.

La comparación entre estos modelos nos permite analizar cómo la introducción de regularización y no linealidad influye en el rendimiento, así como identificar el modelo más adecuado en función del equilibrio entre interpretabilidad, complejidad y capacidad predictiva.

Los modelos lineales han mostrado un rendimiento razonable, con valores de R^2 en torno a 0.74, lo que indica que una parte de la variabilidad puede explicarse mediante relaciones aproximadamente lineales. La incorporación de regularización mediante Ridge y Lasso ha permitido mejorar ligeramente el rendimiento, siendo Lasso el que obtiene mejores resultados dentro de esta familia.

Por otro lado, los modelos no lineales han logrado mejorar de forma más notable el rendimiento. En particular, Random Forest y Gradient Boosting alcanzan valores cercanos a 0.79 en validación, lo que indica que existen relaciones no lineales entre las variables que no son capturadas por los modelos lineales.

El análisis gráfico mediante representaciones de predicción frente a valores reales muestra una buena alineación en torno a la diagonal, especialmente en los modelos basados en árboles, lo que indica un mejor ajuste. Asimismo, la distribución de residuos aparece centrada en cero, sin sesgos sistemáticos, aunque con cierta dispersión que refleja la complejidad del problema.

No obstante, observamos que todos los modelos presentan dificultades en la predicción de valores cercanos a cero, donde la dispersión es mayor. Esto sugiere que la variable objetivo presenta una estructura heterogénea, en la que coexisten estudiantes con rendimiento normal y otros con calificaciones nulas, lo que introduce complejidad adicional en la tarea de regresión.

El modelo de Gradient Boosting ha sido seleccionado como modelo final al presentar el mejor rendimiento en el conjunto de validación como vemos en la figura 3. Una vez seleccionado, se ha reentrenado utilizando el conjunto combinado de entrenamiento y validación, con el objetivo de aprovechar toda la información disponible.

Finalmente, se ha evaluado el modelo en el conjunto de test, obteniendo un R^2 de aproximadamente 0.76. Esta ligera disminución respecto a validación es esperable y confirma que el modelo presenta una buena capacidad de generalización, sin evidencias de sobreajuste significativo.

Adicionalmente, evaluamos la estabilidad del modelo mediante validación cruzada, obteniendo valores de R^2 consistentes entre distintas particiones de los datos. Esto refuerza la robustez del modelo y la fiabilidad de los resultados obtenidos.

En conjunto, los resultados nos muestran que, aunque los modelos lineales ofrecen un rendimiento razonable, los modelos no lineales permiten mejorar la precisión al capturar relaciones más complejas. No obstante, el rendimiento final parece estar limitado por la propia naturaleza de los datos, especialmente por la presencia de valores extremos y la heterogeneidad de la variable objetivo.




Figure 3: Comparación de los modelos en Validación

6 Análisis de la parte no supervisada

Con el objetivo de identificar patrones latentes y posibles perfiles de estudiantes, hemos llevado a cabo un análisis no supervisado utilizando técnicas de reducción de dimensionalidad y clustering.

Para evitar incorporar información futura, excluimos la variable objetivo y aquellas variables del segundo semestre directamente relacionadas con el rendimiento final.

A continuación, se ha empleado el análisis de componentes principales (PCA) para reducir la dimensionalidad del conjunto de datos y facilitar su visualización. Las dos primeras componentes principales explican aproximadamente un 26

Posteriormente, aplicamos el algoritmo K-Means para identificar agrupaciones naturales en los datos. Mediante el método del codo se ha determinado que $k=3$ es un número adecuado de clusters, ya que a partir de este valor la mejora en la inercia es marginal como observamos en la figura 5. La visualización de los clusters en el espacio PCA (figura 6) muestra una separación clara, especialmente a lo largo de la primera componente principal, lo que indica que el algoritmo ha sido capaz de capturar estructuras relevantes.

El análisis de los perfiles medios de cada cluster nos revela la existencia de tres grupos diferenciados de estudiantes. Un primer grupo presenta un rendimiento académico muy bajo, con escasas asignaturas aprobadas y calificaciones reducidas, lo que sugiere un perfil asociado al abandono. Un segundo grupo muestra valores intermedios, representando estudiantes con un rendimiento moderado. Por último, un tercer grupo destaca por un elevado número de asignaturas aprobadas y mejores calificaciones, lo que indica un perfil de alto rendimiento académico.

Adicionalmente, utilizamos un mapa de calor para visualizar las diferencias entre los clusters, observándose en la figura 7, que las principales variaciones se concentran en las variables de rendimiento académico, mientras que otras variables, como las macroeconómicas, presentan menor capacidad discriminativa.

En conjunto, el análisis no supervisado nos permite identificar perfiles de estudiantes claramente diferenciados, poniendo de manifiesto que el rendimiento en el primer semestre es el principal factor asociado a la trayectoria académica posterior.

7 Interpretación crítica de los resultados

Los resultados obtenidos a lo largo del proyecto permiten extraer conclusiones relevantes sobre la capacidad predictiva de los modelos y, al mismo tiempo, ponen de manifiesto varias limitaciones inherentes al problema.

En primer lugar, en la tarea de clasificación se observa que, aunque los modelos alcanzan un rendimiento global similar (en torno a valores de F1 ponderado cercanos), existen diferencias importantes en el comportamiento por clases. En particular, la clase “matriculado”, que presenta




Figure 4: Análisis no supervisado

un menor número de observaciones, resulta sistemáticamente más difícil de predecir. Este hecho evidencia el impacto del desbalanceo de clases, ya que los modelos tienden a favorecer las categorías mayoritarias como “graduado”. Por tanto, métricas globales pueden ocultar deficiencias relevantes en clases minoritarias, lo que resulta crítico en un contexto aplicado donde identificar estudiantes en situaciones intermedias o de riesgo es especialmente importante.

En la tarea de regresión, los resultados muestran que los modelos lineales ya capturan una parte significativa de la variabilidad del rendimiento académico del segundo semestre. La mejora limitada aportada por técnicas de regularización sugiere que la relación entre las variables disponibles y la variable objetivo es en gran medida lineal o que la información contenida en los predictores es suficiente pero no especialmente compleja. No obstante, el hecho de eliminar variables del segundo semestre para evitar data leakage implica que el modelo trabaja con información incompleta respecto al fenómeno real, lo que limita su capacidad predictiva y debe tenerse en cuenta al interpretar los resultados.

En cuanto a la parte no supervisada, los clusters obtenidos permiten identificar perfiles diferenciados de estudiantes, pero no reproducen exactamente las clases originales. Esto es coherente con la naturaleza del aprendizaje no supervisado, cuyo objetivo es descubrir estructuras latentes en los datos y no necesariamente replicar etiquetas conocidas. Sin embargo, la interpretación de los clusters debe hacerse con cautela, ya que su significado depende fuertemente de las variables seleccionadas y de la técnica utilizada.

De forma global, los resultados sugieren que variables relacionadas con el rendimiento académico temprano (especialmente del primer semestre) tienen un papel clave en la predicción del éxito académico, mientras que factores socioeconómicos y demográficos aportan información complementaria pero con menor poder predictivo directo. No obstante, es importante destacar que estas relaciones son correlacionales y no causales, tal y como se advierte en el planteamiento del proyecto.

Finalmente, desde una perspectiva crítica, este estudio presenta varias limitaciones. Por un lado, la calidad de las predicciones está condicionada por la información disponible y por decisiones metodológicas como la selección de variables o el tratamiento del desbalanceo. Por otro, los modelos utilizados no capturan necesariamente relaciones causales ni factores externos no observados que pueden influir en la trayectoria académica del estudiante. En consecuencia, los resultados deben interpretarse como una herramienta de apoyo a la toma de decisiones y no como un sistema determinista.

En conjunto, este análisis pone de relieve la importancia de complementar el rendimiento predictivo con una interpretación cuidadosa y contextualizada, especialmente en problemas con implicaciones reales como el abandono académico.

8 Conclusiones

En conjunto, comprobamos que el rendimiento académico temprano es un indicador clave y que los modelos son capaces de capturar patrones útiles, aunque con un margen de mejora limitado. Esto sugiere que, con la información disponible, existe un techo en la capacidad predictiva que no puede superarse únicamente con modelos más complejos.

El uso combinado de técnicas supervisadas y no supervisadas ha resultado especialmente útil, ya que no solo permite predecir, sino también comprender mejor la estructura de los datos y los distintos perfiles de estudiantes.

No obstante, el estudio presenta limitaciones importantes. Por un lado, la información disponible no recoge todos los factores que influyen en la trayectoria académica (motivación, entorno personal, etc.). Por otro, las decisiones metodológicas adoptadas condicionan los resultados obtenidos.

En consecuencia, consideramos que estos resultados pueden servir como apoyo a la toma de decisiones, pero deben complementarse con análisis adicionales y conocimiento del contexto educativo.

Bibliografía

- Documentación de Scikit-learn: <https://scikit-learn.org>
- Apuntes de la asignatura Machine Learning (ICAI)